

- Data Leakage Analysis Report
  - PhiUSIIL Phishing URL Dataset (63 Features)
  - Executive Summary
  - 1. Apa itu Data Leakage?
  - 2. Bukti Data Leakage dalam Dataset
    - 2.1 Temuan Utama
    - 2.2 Visualisasi Masalah
  - 3. Dampak terhadap Model Performance
    - 3.1 Accuracy yang Tidak Realistik
    - 3.2 Mengapa Model Bisa "Curang"
  - 4. Analisis Per-Feature
    - 4.1 URLSimilarityIndex (Correlation: 0.86)
    - 4.2 IsHTTPS (Correlation: 0.61)
    - 4.3 has\_no\_www (Correlation: 0.67)
    - 4.4 num\_slashes (Correlation: 0.48)
    - 4.5 URL Query Parameters (NoOfEqualsInURL, NoOfQMarkInURL, NoOfAmpersandInURL)
    - 4.6 Obfuscation Features (HasObfuscation, NoOfObfuscatedChar, ObfuscationRatio)
  - 5. Kemungkinan Penyebab
    - 5.1 Error dalam Feature Extraction
    - 5.2 Dataset Collection Bias
    - 5.3 Feature Engineering Error
  - 6. Rekomendasi
    - 6.1 Untuk Training Model
    - 6.2 Untuk Feature Selection
    - 6.3 Untuk Reporting
  - 7. Hasil Setelah Menghapus URLSimilarityIndex
  - 8. Kesimpulan
  - Appendix: Code untuk Verifikasi

# Data Leakage Analysis Report

---

## PhiUSIIL Phishing URL Dataset (63 Features)

---

**Date:** January 28, 2026

**Dataset:** PhiUSIIL\_Phishing\_URL\_63\_Features.csv

**Total Samples:** 235,795 (Phishing: 134,850 | Legitimate: 100,945)

---

# Executive Summary

---

[!CAUTION] **11 features dalam dataset ini mengalami DATA LEAKAGE** - semua samples phishing memiliki nilai yang IDENTIK untuk features ini, memungkinkan model untuk "curang" dan mencapai accuracy 99.99% tanpa benar-benar belajar pola phishing yang sebenarnya.

---

## 1. Apa itu Data Leakage?

---

**Data Leakage** adalah kondisi di mana informasi dari target variable (label) secara tidak sengaja "bocor" ke dalam feature variables. Ini menyebabkan:

- Model mencapai **accuracy yang tidak realistik** (terlalu tinggi)
  - Model **tidak dapat generalize** ke data baru
  - **Hasil penelitian menjadi invalid** karena performa yang dilaporkan tidak mencerminkan kemampuan sebenarnya
- 

## 2. Bukti Data Leakage dalam Dataset

---

### 2.1 Temuan Utama

Analisis menunjukkan bahwa **11 features memiliki nilai KONSTAN untuk SEMUA 134,850 samples phishing**:

No	Feature	Nilai Phishing (ALL 134,850)	Nilai Legitimate (100,945)	Correlation dengan Label
1	<b>URLSimilarityIndex</b>	100.0	0.16 - 100.0 (mean: 49.6)	0.8604
2	<b>IsHTTPS</b>	1	0 - 1 (mean: 0.49)	0.6129
3	<b>has_no_www</b>	0	0 - 1 (mean: 0.59)	0.6684
4	<b>num_slashes</b>	2	2 - 68 (mean: 3.02)	0.4822
5	<b>IsDomainIP</b>	0	0 - 1 (mean: 0.006)	-
6	<b>NoOfEqualsInURL</b>	0	0 - 176 (mean: 0.15)	-
7	<b>NoOfQMarkInURL</b>	0	0 - 4 (mean: 0.07)	-
8	<b>NoOfAmpersandInURL</b>	0	0 - 50 (mean: 0.08)	-
9	<b>HasObfuscation</b>	0	0 - 1 (mean: 0.005)	-
10	<b>NoOfObfuscatedChar</b>	0	0 - 149 (mean: 0.06)	-
11	<b>ObfuscationRatio</b>	0.0	0 - 0.35 (mean: 0.0003)	-

## 2.2 Visualisasi Masalah

URLSimilarityIndex Distribution

Phishing:  ALL = 100.0

Legitimate:  0.16 100.0

→ Model hanya perlu cek: IF URLSimilarityIndex == 100 → Phishing

## 3. Dampak terhadap Model Performance

### 3.1 Accuracy yang Tidak Realistik

Kondisi	Accuracy Range
Dengan 11 leaking features	99.95% - 100.00%
Setelah hapus URLSimilarityIndex saja	98.70% - 100.00%
Estimasi tanpa semua leaking features	~95% - 97%

### 3.2 Mengapa Model Bisa "Curang"

Model machine learning dapat membuat rules sederhana seperti:

```
# Rule 1: Cukup lihat URLSimilarityIndex
if URLSimilarityIndex == 100.0:
    return "Phishing" # 100% akurat untuk semua phishing

# Rule 2: Kombinasi features
if IsHTTPS == 1 and num_slashes == 2:
    return "Phishing" # Hampir 100% akurat

# Rule 3: Features "kosong"
if NoOfEqualsInURL == 0 and NoOfQMarkInURL == 0 and NoOfAmpersandInURL == 0:
    return "Phishing" # Sangat akurat
```

## 4. Analisis Per-Feature

### 4.1 URLSimilarityIndex (Correlation: 0.86)

[!WARNING] Feature paling berbahaya - memiliki korelasi tertinggi dengan label.

- **Phishing:** ALL values = 100.0 (tidak ada variasi sama sekali)
- **Legitimate:** Range 0.16 - 100.0 dengan distribusi normal
- **Implikasi:** Feature ini hampir pasti dihitung menggunakan informasi label, atau ada error dalam extraction

## 4.2 IsHTTPS (Correlation: 0.61)

- **Phishing:** ALL values = 1 (semua phishing menggunakan HTTPS)
- **Legitimate:** Mix 0 dan 1 (48.7% menggunakan HTTPS)
- **Masalah:** Tidak realistik bahwa 100% phishing website menggunakan HTTPS

## 4.3 has\_no\_www (Correlation: 0.67)

- **Phishing:** ALL values = 0 (semua phishing memiliki "www")
- **Legitimate:** 58.5% tidak memiliki "www"
- **Masalah:** Tidak realistik bahwa semua phishing URL memiliki format yang sama

## 4.4 num\_slashes (Correlation: 0.48)

- **Phishing:** ALL values = 2 (hanya <https://domain.com/>)
- **Legitimate:** Range 2 - 68 (ber variasi)
- **Masalah:** Artinya tidak ada phishing URL dengan path tambahan - sangat tidak realistik

## 4.5 URL Query Parameters (NoOfEqualsInURL, NoOfQMarkInURL, NoOfAmpersandInURL)

- **Phishing:** ALL values = 0 untuk ketiga features
- **Masalah:** Artinya tidak ada phishing URL dengan query string ([?param=value](#)) - tidak masuk akal karena banyak phishing menggunakan tracking parameters

## 4.6 Obfuscation Features (HasObfuscation, NoOfObfuscatedChar, ObfuscationRatio)

- **Phishing:** ALL values = 0 untuk ketiga features
  - **Masalah:** Phishing URLs seharusnya LEBIH MUNGKIN menggunakan obfuscation, bukan tidak sama sekali
- 

## 5. Kemungkinan Penyebab

### 5.1 Error dalam Feature Extraction

Kemungkinan skenario:

1. Script extraction memiliki bug untuk phishing samples
2. Default values diassign ketika extraction gagal
3. Features dihitung dari sumber data yang berbeda

### 5.2 Dataset Collection Bias

Kemungkinan skenario:

1. Semua phishing URL dikumpulkan dari satu sumber spesifik
2. Phishing samples terlalu homogen (tidak representatif)
3. Pre-processing menghapus variasi dalam phishing samples

### 5.3 Feature Engineering Error

Kemungkinan untuk URLSimilarityIndex:

1. Dihitung dengan membandingkan URL ke database known phishing
2. Menggunakan informasi label dalam perhitungan
3. Formula yang salah menghasilkan nilai konstan

## 6. Rekomendasi

## 6.1 Untuk Training Model

[!IMPORTANT] HAPUS semua 11 features dari dataset sebelum training:

```
leaking_features = [  
    'URLSimilarityIndex',  
    'IsHTTPS',  
    'has_no_www',  
    'num_slashes',  
    'IsDomainIP',  
    'NoOfEqualsInURL',  
    'NoOfQMarkInURL',  
    'NoOfAmpersandInURL',  
    'HasObfuscation',  
    'NoOfObfuscatedChar',  
    'ObfuscationRatio'  
]  
  
X = X.drop(columns=leaking_features)
```

## 6.2 Untuk Feature Selection

- Jalankan ulang feature selection **SETELAH** menghapus 11 leaking features
- Ini akan menghasilkan top features yang benar-benar informatif

## 6.3 Untuk Reporting

- **JANGAN** gunakan accuracy 99.99% dalam paper/thesis
- Gunakan hasil dari **Boruta** yang tidak mengandung leaking features (98.70% - 99.56%)
- Atau train ulang dengan dataset yang sudah dibersihkan

## 7. Hasil Setelah Menghapus URLSimilarityIndex

Feature Set	Model	Accuracy (Sebelum)	Accuracy (Setelah)
Boruta	Random Forest	99.99%	99.43% 

Feature Set	Model	Accuracy (Sebelum)	Accuracy (Setelah)
Boruta	XGBoost	99.99%	99.56% <span style="color: green;">✓</span>
Boruta	SVM	99.95%	98.70% <span style="color: green;">✓</span>
RFE	Random Forest	100.00%	99.89% <span style="color: orange;">⚠</span>
RFE	XGBoost	100.00%	99.93% <span style="color: orange;">⚠</span>
All Features	Random Forest	100.00%	100.00% <span style="color: red;">✗</span>

[!NOTE] **Boruta** memberikan hasil paling realistik karena feature set-nya tidak mengandung leaking features. **All Features** masih 100% karena 10 leaking features lainnya masih ada.

## 8. Kesimpulan

1. **Dataset PhiUSIIL memiliki masalah serius** dengan 11 features yang leak informasi label
2. **Accuracy 99.99% adalah INVALID** - bukan performa model yang sebenarnya
3. **Perlu pembersihan dataset** sebelum digunakan untuk penelitian
4. **Hasil Boruta (98.70% - 99.56%)** adalah yang paling mendekati performa realistik
5. **Untuk penelitian yang valid**, hapus semua 11 leaking features dan run ulang eksperimen

## Appendix: Code untuk Verifikasi

```

import pandas as pd

# Load dataset
df = pd.read_csv('PhiUSIIL_Phishing_URL_63_Features.csv')

# Split by label
phishing = df[df['label'] == 1]
legitimate = df[df['label'] == 0]

# Check each feature
leaking_features = []
for col in df.select_dtypes(include=['number']).columns:
    if col == 'label':

```

```
    continue
if phishing[col].nunique() == 1:
    print(f"{col}: Phishing ALL = {phishing[col].iloc[0]}")
    leaking_features.append(col)

print(f"\nTotal leaking features: {len(leaking_features)}")
```

---

**Report Generated:** January 28, 2026

**Analysis Tool:** Python + Pandas